

Análisis de Pasajeros Aéreos Internacionales

Análisis de Series de Tiempo I - Trabajo Final

Integrantes: Josmar Katherin Brazón, Carla Sabrina Espínola Hamm, Sabrina Daiana Pryszczuk

Docente: Camilo Argoty

Introducción y **Pregunta de Investigación**

Contexto del Dataset

Utilizamos el dataset clásico "**Air Passengers**" (Box & Jenkins, 1976), que registra la demanda mensual entre enero de 1949 y diciembre de 1960.

Pregunta de Investigación

¿Qué modelo (HW, SARIMA o AutoARIMA) predice con mayor precisión el período de prueba 1959-1960?

Hipótesis: Los modelos multiplicativos superarán a los aditivos debido a la amplitud creciente de la serie.



Descripción de los Datos



Origen

Benchmarking de referencia en el campo. Datos mensuales de aerolíneas internacionales (en miles).



Dimensiones


144 observaciones totales (12 años x 12 meses). Dataset limpio, sin valores nulos ni duplicados.



Propiedades

Tendencia lineal creciente.
Estacionalidad anual con picos marcados en julio y agosto.

Análisis Visual (EDA)





Observaciones Clave

- **Tendencia:** Crecimiento exponencial sostenido de la demanda.
- **Estacionalidad:** Patrón cíclico de 12 meses (Verano boreal).
- **Residuos:** Fluctuaciones irregulares capturadas mediante descomposición multiplicativa.

La amplitud estacional aumenta proporcionalmente al nivel de la serie, confirmando la naturaleza multiplicativa.

Análisis Visual (EDA)



La amplitud estacional aumenta proporcionalmente al nivel de la serie, confirmando la naturaleza multiplicativa.

Preparación y Estacionariedad

0.99

p-value Test ADF

0.82

Estadístico ADF

Valores críticos

1%: -3.4817

5%: -2.8840

10%: -2.5788

La serie es **no estacionaria**. Requiere diferenciación (d=1, D=1) para modelos ARIMA.

Partición del Dataset

Mantenemos un orden cronológico estricto para la validación:

Entrenamiento (Train): Ene 1949 - Dic 1958 (120 meses)

Prueba (Test): Ene 1959 - Dic 1960 (24 meses)

Modelo 1: Holt-Winters



Suavizamiento Exponencial Triple

Modelado directo de nivel (α), tendencia (β) y estacionalidad (γ).

- **Tendencia:** Aditiva.
- **Estacionalidad:** Multiplicativa (Periods=12).
- **Precisión:** Excelente ajuste visual al periodo de prueba.

RMSE: 32.49

MAE: 28.98



Modelo 2: SARIMA



SARIMA(1,1,1)(1,1,1)[12]

Modelo estadístico estándar que asume una estructura aditiva si no se transforma la serie.

- Captura correlaciones de corto y largo plazo.
- Los coeficientes AR y MA no resultaron significativos.
- Falla al no considerar el cambio de amplitud.

RMSE: 75.63

MAE: 69.90



Modelo 3: AutoARIMA



Selección Automatizada

Búsqueda sistemática de parámetros óptimos minimizando el Criterio de Información de Akaike (AIC).

- **Mejor modelo:** $(2,0,0) \times (0,1,0)_{12}$.
- Optimiza la complejidad del modelo.
- Supera al SARIMA manual pero sigue por debajo de HW.

RMSE: 47.23


MAE: 43.46



Comparación de Métricas

Modelo	RMSE (Test)	MAE (Test)
Holt-Winters	32.49	28.98
SARIMA (1,1,1)(1,1,1)12	75.63	69.90
AutoARIMA	47.23	43.46

CONCLUSIÓN FASE 1:
Holt-Winters gana por su capacidad nativa de manejar estacionalidad multiplicativa.



Extensión: Transformación Logarítmica

Impacto del Logaritmo

Al aplicar $\log(X_t)$, convertimos la relación multiplicativa en aditiva, permitiendo que ARIMA brille.

SARIMA-Log

48.25

AutoARIMA-Log

14.10



Holt-Winters

32.49

Resultado Ganador

AutoARIMA-Log reduce el error a menos de la mitad (RMSE 14.10).

La transformación de varianza es el factor determinante en la precisión.



Diagnóstico de Residuos

SARIMA



No logra estabilizar la varianza a lo largo del tiempo (heterocedasticidad). Los residuos crecen a medida que aumenta el nivel de la serie.

Modelo estadísticamente mal especificado al asumir estacionalidad aditiva.

AutoARIMA

No supera los tests diagnósticos de Ljung-Box. La distribución se aleja de la normalidad y existe autocorrelación remanente.

Estructura insuficiente para capturar la dinámica multiplicativa de los datos.




Diagnóstico de Residuos

SARIMA-Log

Pasa el test de Ljung-Box. Los residuos son **ruido blanco** (sin autocorrelación).


Modelo estadísticamente bien especificado.



AutoARIMA-Log

No pasa los tests diagnósticos a pesar de tener el menor error RMSE.

Existe correlación remanente en los residuos.



Análisis del Test Ljung-Box

MODELO	P-VALUE (LAG 12)	P-VALUE (LAG 24)	RUIDO BLANCO (12)	RUIDO BLANCO (24)
SARIMA(1,1,1)(1,1,1)[12]	0.6777	0.8597	✓ True	✓ True
AutoARIMA (2, 0, 0)x(0, 1, 0, 12)	0.0000	0.0000	✗ False	✗ False
SARIMA-Log(1,1,1)(1,1,1)[12]	0.1986	0.7724	✓ True	✓ True
AutoARIMA-Log (2, 0, 0)x(0, 1, 1, 12)	0.0000	0.0000	✗ False	✗ False

Conclusión general y lecciones aprendidas



Conclusión General

Modelo Ganador (Sin Log): Holt-Winters confirma que la estacionalidad multiplicativa es el factor clave de precisión.

Dicotomía Ajuste vs. Diagnóstico: AutoARIMA-Log es el mejor en predicción puntual, pero sus intervalos no son confiables.

SARIMA-Log como opción sólida: Es el modelo mejor especificado, equilibrando un bajo error con residuos de ruido blanco.

Advertencia Central: Un buen ajuste numérico en test no garantiza haber capturado toda la estructura de la serie.



Lecciones Aprendidas

Tratamiento de Varianza: Modelar la naturaleza multiplicativa (vía HW o Log) mejora sistemáticamente el error de pronóstico.

Métricas Distintas: El RMSE mide calidad de pronóstico; el diagnóstico residual mide captura de información disponible.

Impacto de Outliers: Observaciones atípicas (años 50) afectan la normalidad sin arruinar necesariamente el ajuste general.

Valor de la Intuición: La automatización minimiza el error, pero el ajuste manual permite lograr una mayor robustez estadística.

¿Preguntas?

¡Muchas gracias por su atención!

Repo: <https://github.com/jbrazonath/Analisis-de-Series-de-Tiempo>